

Pesquisa acadêmica com agentes de IA

Um experimento de criação de dissertação e artigo

Codex na execução

Gemini em dois ciclos de revisão

A pergunta do experimento

O que esperamos de um pesquisador quando parte da pesquisa pode ser delegada a agentes?

Produto científico

A pergunta importa?
Os resultados se sustentam?

Formação da pessoa

Ela compreende o trabalho?
Consegue decidir o próximo passo?


O ponto de partida

Um trabalho de graduação

Uma intenção ampla

Nenhuma hipótese nova fornecida no início

Pedido: propor uma continuação de mestrado, implementar e validar.



Quem tomou quais decisões

Usuário	Definiu a intenção, acompanhou recursos e encaminhou feedback.
Codex (Astra)	Formulou o recorte, implementou, testou e redigiu.
Gemini	Revisou a dissertação e, depois, o manuscrito.

Cronologia do experimento

Quando	Marco
10 set.	TG, proposta e início do goal
11 set.	Simulações, resultados parciais e pausa
12 set.	Retomada e parecer sobre a dissertação
13 set., 01:04	Goal concluído e dissertação consolidada
13 set., 11:14	Manuscrito revisado após novo parecer

Como o agente procurou novidade

Antecedentes

Reconheceu resultados já publicados.

Alternativas

Comparou possíveis extensões teóricas e numéricas.

Recorte

Escolheu testar quando simplificações mudam uma análise.

Originalidade candidata, ainda sujeita a avaliação especializada.

Execução orientada por etapas

13 marcos concluídos

Construção Revisão, base teórica, modelo e simulador.

Experimentos Calibração, comparações e robustez.

Consolidação Reprodução, dissertação e manuscrito.

Os produtos do estudo

Dissertação apresentada à Pró-Reitoria de Pós-Graduação do Instituto Tecnológico de Aeronáutica, como parte dos requisitos para obtenção do título de Mestre em Ciências no Programa de Pós-Graduação em Física, Área de Física Nuclear.

Gráviton de Souza

MASSA DO GRÁVITON E POLARIZAÇÕES DE
ONDAS GRAVITACIONAIS EM PTAS: EFEITOS
DA COMPRESSÃO EM FREQUÊNCIA E
VALIDAÇÃO ESTATÍSTICA

Dissertação submetida à avaliação da banca examinadora.

Prof. Dr. Schrödinger GPT de Gotham
Orientador

Campo Montenegro
São José dos Campos, SP - Brasil
2026

Dissertação: 167 páginas

Separating compression, likelihood approximation and dispersive
response errors in simulated pulsar timing arrays

Gráviton de Souza

Revised manuscript; 13 September 2026

Abstract

Graviton-mass inference from pulsar timing arrays can change when data are summarized, their sampling distribution is approximated, or the dispersive response is replaced by a reference-frequency template. We introduce a controlled comparison framework that distinguishes these three operations in a periodic Fourier experiment. Matched observations isolate response changes, while an exactly Gaussian control separates compression bias from misspecification of physical quadratic estimators. The normal estimator likelihood exhibits a persistent calibration rejection even with known nuisance parameters. In the Gaussian control, frequency compression removes on average 0.062 and 0.106 rad in two simulated array configurations. Reference-frequency substitutions produce small mean upper-quantile shifts in a resolved conditional sample, where the compressed data are weakly informative; this is a regime-specific sensitivity result. Finally, a uniform prior on $u \in [0, 1]$ yields an upper quantile of 0.95 with zero information gain when the likelihood is constant. We propose reporting posterior learning, prior sensitivity and calibration alongside mass limits. A precise upper limit is physically informative only when its relation to the assumed prior and the statistical model is established.

1 Introduction

Pulsar timing arrays (PTAs) provide a setting in which gravitational-wave propagation and polarization can be tested through correlations between pulsar signals. Analyses of the NANOGrav 15-year data set have already addressed graviton mass and transverse non-Einsteinian polarization modes [1, 2]. Interpreting such tests requires a response that connects a gravity model to frequency-dependent correlations. Dispersive calculations with Earth and pulsar terms [3], together with finite-distance treatments of the overlap reduction function [4], establish the physical ingredients of that response.


A practical inference may nevertheless act on compressed correlation products rather than the underlying multifrequency data. A concrete example is Zhao and Wang [5]: their frequency-compressed angular correlations motivate the choice $f_{\text{ref}} = 1/T$ for mapping mass to propagation speed, whereas unavailable inter-bin covariance motivates a diagonal Gaussian likelihood. These are distinct choices. Our experiment is motivated by this separation; it does not reproduce that observational likelihood or determine the validity of its reported limits.

Three operations can intervene between Fourier data and a mass posterior: approximating the distribution of quadratic estimators by a normal law, compressing their frequency dependence, and substituting a reference-frequency response. If they change together, a posterior shift does not identify its cause. Existing work has examined non-Gaussian stochastic-background likelihoods and compression [6], and full-covariance multifrequency mass forecasts are available [7]. The question addressed here is how to distinguish these operations within one paired dispersive-PTA experiment, with numerical uncertainty propagated into the statistical conclusions.

We develop a controlled comparison framework, summarized in Fig. 1, with three contributions:

Artigo: 9 páginas

Escala do trabalho executado



26.069

linhas em módulos,
scripts e testes

45.528

análises principais

Base histórica v1.0.0. Quantidade mede execução, não qualidade científica.

Tempo de execução e tempo de formação

30 h 51 min

contador do goal original

**Compreender e
validar exigem
tempo próprio.**

54 h 56 min

intervalo no calendário, com pausas

Um controle expôs confiança excessiva

90%

Cobertura nominal
esperada

62,6%

Cobertura observada
em um parâmetro

313 de 500 casos continham a verdade simulada.

As simulações permitiram detectar uma limitação da aproximação.

Correções e perguntas ainda abertas

Texto

Corrigiu uma descrição incompatível com o código.

Execução

Recuperou cálculos e insumos após falhas operacionais.

Escopo

Resolveu um estudo mais restrito, preservando a inconclusão ampla.

Dois ciclos de revisão com Gemini

Dissertação

Críticas científicas
Novos estudos pontuais
Revisão do texto e figuras

Manuscrito

Estrutura e interpretação
Fluxograma e referências
Resultados existentes

O usuário mediu a revisão e o Codex conferiu as recomendações.

O Codex filtrou o segundo parecer

Melhorias incorporadas

Contribuição mais clara
Resultados reorganizados
Diagrama explicativo

Generalizações limitadas

Ineditismo absoluto
Falha inevitável em dados reais
Causas não demonstradas

A revisão ampliou o artigo de 7 para 9 páginas, sem novas simulações.

O que o caso demonstra

Evidência disponível

Formulação e execução extensas
Controles e correções
Produtos reproduzíveis no escopo

Questões abertas

Originalidade definitiva
Qualidade julgada por especialistas
Aprendizagem e ganho de produtividade

A divisão do trabalho pode mudar

Mais capacidade de explorar ideias

Trabalho delegável

Primeiras formulações
Código e controles
Organização dos resultados

Trabalho a avaliar

Escolha da pergunta
Julgamento das evidências
Decisão de continuar ou parar

Formação precisa aparecer no processo

Antes de executar	Explicar a hipótese e prever o efeito de uma mudança.
Durante o trabalho	Interpretar controles e justificar escolhas.
Ao concluir	Reconstruir o argumento e responder por seus limites.

Relevância e capacidade de revisão

Mais resultados exigem mais capacidade de julgar o que importa

Uma contribuição pode valer pela pergunta que resolve, pela incerteza que elimina ou pelo limite que estabelece.

Contagem de artigos e volume de código não substituem essa avaliação.

Próximas avaliações do experimento

Qualidade científica

Especialistas examinam as conclusões centrais.

Efeito da revisão

Comparação cega entre versões do manuscrito.

Formação e custo

Medidas de compreensão e esforço total de verificação.

Questões para discussão

Que competências precisam ser demonstradas pessoalmente?

Que perguntas passam a valer a pena quando executar custa menos?

Como repartir o esforço de verificar?

Apoio: leitura correta das métricas

Medida	Definição
26.069 linhas	Módulos, scripts e testes, com linhas vazias
91.347 linhas	Inclui código arquivado e cópias, sem deduplicação
45.528 análises	Quatro campanhas, com dados compartilhados
25.719.766 tokens	Campo tokensUsed do goal, sem conversão em custo

Apoio: documentos e fontes

Repositório TGdoWayne

github.com/flavioluiz/TGdoWayne

Relatório do estudo de caso e evidências

Notas da revisão do manuscrito

Dissertação v1.0.0 e arquivos de reprodução

Roteiro desta apresentação com fontes por slide